

Succinct Filters Review (v1)

Succinct Filters for Sets of Unknown Sizes: 论文 Review (整合稿 v0.1)

- **状态**: Day 6 第一版整合; **非终稿**
 - **整合说明**: 技术直觉 / 实现 / 正确性与时间证明由张书铖 (B) 定稿并入; 问题定义、主结果、下界、相关研究、评价等章在 A/C 的 Day 5 章节定稿前, 仅保留**可追溯的笔记级桥接**, 并标【待 A】【待 C】。未关闭 Q1/Q3 在正文中显式保留。
 - **贯穿教学示例**: 连续插入 8 个抽象元素 $x_1 \dots x_8$ (§ 6.5); 不承担一般证明。
 - **图示**: figures/architecture.md、figures/query-insert-flow.md、figures/growth-process.md、figures/proof-dependency.md
-

1. 摘要

【待 A 定稿】桥接要点: 在集合最终规模未知时, 维护动态 approximate membership (filter) 与 dictionary; filter 空间在适当条件下达 $(1+o(1))n(\log(1/\epsilon)+\log \log n)$ 位, 插入与查询在无 failure 时为 worst-case $O(1)$ (整段序列 failure 概率 $\leq \delta$)。本 Review 解释问题为何难、相对 PSW 的改进、构造与证明如何核查, 并标明小组未关闭缺口。

2. 引言

【待 A 定稿】桥接要点: membership 应用广泛; dictionary 精确、filter 允许误报但不允许漏报; 传统结构常按容量上界 N 占空间; 当 $n \ll N$ 或 N 不可靠时浪费严重。核心问题: 空间能否始终依赖当前规模, 同时保持误报、无漏报与最坏情况常数时间?

下文先给出问题与结果 (A)，再述相关工作 (C)，然后展开构造与证明 (B)，最后评价与后续 (C)。

3. 问题定义和研究意义

【待 A 整合 definitions.md / Day 5 问题章】

全局符号（全文统一；log 以 2 为底）

符号	含义
$[u]$	全集 $\{0, \dots, u-1\}$
n	插入次数 (insertion-sequence)；与去重后 $ s $ 的差别见 A
ϵ	误报率 (false positive rate)
$\delta = u^{-C}$	曾报告 failure 的概率上界
N	传统预置容量上界（本文希望摆脱对紧 N 的依赖）

口径：正确性与时间保证均 **conditioned on no failure**； ϵ 与 δ 不可混用。

4. 相关研究

【待 C 整合】读者测试意见见 discussions/review-day6.md（B 测相关工作笔记）。
分层提醒：Bloom / scalable • dynamic Bloom / succinct dictionary / quotient • cuckoo / PSW / 2020 后工作不可排成单一“更优”序列。

5. 论文主要结果

【待 A 定稿】与构造对照时采用：

- **正式 Theorem 10**: $n = w(\log u)$ 、 $n < u$ ；主体空间 $n(\log(1/\epsilon) + \log \log n + O(\log \log \log u))$ + 输入无关 u^c ；无 failure 时 $FP \leq \epsilon$ 、操作 $O(1)$ ； $failure \leq \delta$ 。
- **非正式 Theorem 1**: $n > u^{\{0.001\}}$ 等条件下写成 $(1+o(1))\dots$ ；**不得**把该条件写成 Thm 10 的唯一前提。
- **相对 PSW**：在 $\epsilon = o(1)$ 等条件下钉死 $\log \log n$ 领先常数，并给出 whp 最坏 $O(1)$ 而非期望均摊插入（评价措辞见 C；最优性依赖 PSW 下界）。

6. 核心技术直觉

6.1 总路线

在最终规模未知时，构造目标是：空间跟随当前 n ，无漏报，误报 $\leq \epsilon$ ，且在无 failure 时插入/查询为 worst-case $O(1)$ 。

总路线：

- 1. 全局哈希 h 把 key 映成长比特串，**不保存**原始 key。
- 2. 第 n 次插入只写入 $h(x)$ 的前 $\ell_{i\star(n)}$ 位，其中 $i\star(n)=\lceil \log n \rceil$ 。
- 3. 查询化为 prefix matching：是否存在已存串 s 为 $h(y)$ 的前缀。
- 4. 短前缀用真值表 τ ，长前缀用已知容量结构 $D(m,\ell)$ ；未知规模由「两代 D/τ 并存 + 后台迁移」拼装 (Claim 13 $\rightarrow$ Lemma 11 $\rightarrow$ Theorem 10)。

相对 PSW：真值表处理短串；去均摊、可查询的迁移；更紧底层冗余以支撑 $\log \log n$ 项领先常数（条件见 A）。

体系结构见 `figures/architecture.md`。

6.2 变长前缀与误报预算

论文命题（§ 3.1 式 (2)）：

$$\ell_i = i + \log(1/\epsilon) + \log i + \log \log \log u + 2$$

项	作用
i	随阶段增长加长前缀
$\log(1/\epsilon)$	主误报成本
$\log i$	跨阶段并合预算
$\log \log \log u、+2$	冗余与并合余量

非成员误报经阶段内前缀数与 $2^{-\ell_i}$ 的 union bound 受控（**精算见 A**）。迁移只改存放位置，**不改变**该前缀写入时所按的 ℓ_i 预算。

6.3 四个活跃结构

操作参数 $i=i\star(n)$ ：

结构	职责
D_i	当前长前缀主写入

结构	职责
$D_{\{i-1\}}$	旧长前缀；迁移源；仍可查
T_i	短串；接收迁移
$T_{\{i-1\}}$	更短层；迁出时扩展为 $y \circ 0, y \circ 1$

「已初始化」的下一层可能存在，但 **Lookup 不查询它们**。

开放缺口 (Q1/Q3): Claim 13 证明段半开区间句与 $i \star$ 下标冲突未形式关闭；正文操作一律跟算法句 $i \star$ 。见 discussions/issues/issue-stage-index.md。

小边界: $n=1$ 时无 $D_{\{-1\}}/T_{\{-1\}}$ ；式 (2) 并合自 $i \geq 1$, ℓ_0 特判待与 A 统一。

6.4 为何不是“可扩容 Bloom”

工程 scalable/dynamic Bloom 可增长，但通常查询多个组件、空间/时间保证与本文 word-RAM 定理不同 (C)。本文要同时：空间相对当前 n 的 succinct 主项、只查常数结构、whp 最坏 $O(1)$ 。

6.5 贯穿教学示例（唯一）

连续插入 $x_1 \dots x_8$ （人为示意前缀，**非**真实哈希，**不**证明概率/空间）：

n	$i \star$	新键进入	查询活跃	维护推进
1	0	D_0	D_0, T_0	—
2	1	D_1	D_0, D_1, T_0, T_1	迁 T_0/D_0 ；init T_2/D_2
3–4	2	D_2	D_1, D_2, T_1, T_2	迁 T_1/D_1 ；init T_3/D_3
5–8	3	D_3	D_2, D_3, T_2, T_3	迁 T_2/D_2 ；init T_4/D_4

同步图：figures/growth-process.md。

7. 数据结构详细实现

7.1 算法说明（抽象；非工程代码）

状态： n , h , $failed$, 各层 $T[j], D[j]$, $init/destroy$ 进度。
 $i \star(n) = \lceil \log n \rceil$, ℓ_i 如式 (2), $Pref(z, L)$ 为前 L 比特。

Lookup(y) ($\neg \text{failed}$, $n \geq 1$): $i \leftarrow i \star (n)$, $z \leftarrow h(y)$; 若 $D_{i-1}/D_i/\tau_{i-1}/\tau_i$ 任一
对相应前缀查询命中则 YES, 否则 NO。至多四次底层 query。

Insert(x): $n \leftarrow n+1$, $i \leftarrow i \star (n)$, $s \leftarrow \text{Pref}(h(x), \ell_i)$; 若无更短前缀覆盖则
 $D.\text{insert}(D_i, s)$ (失败则 $\text{failed} \leftarrow \text{true}$); 再执行 **10** 次维护步 (原文)。

一轮维护 (MigrateOneStep(i)), 对应 Claim 13:

1. 若 τ_{i-1} 非空: decrement 得 y , 则写入 τ_i 的 $y \circ 0$ 与 $y \circ 1$;
2. 若 D_{i-1} 非空: decrement 得 y , 则 $|y| > i$ 进 D_i , 否则进 τ_i ;
3. 旧层已空则推进 destroy ;
4. 旧层已销毁则推进 $\text{initialize}(\tau_{i+1})$, $\text{initialize}(D_{i+1})$ 。

完整状态机见 [notes/memberB/pseudocode.md](#)。

字面常数 10: 原文每次执行 10 轮; **小组未从黑盒 $o(m)$ 隐藏常数独立复算其充分性 (Q3)**。渐近上存在足够大的常数轮数。

写入层就绪: 单次 Insert **不得** while 到初始化完成; 依赖阶段就绪不变式 + 每插
常数轮推进。

7.2 底层 $D(m, \ell)$

黑盒: $\text{initialize/destroy}$ (各 $O(m)$ 次调用完成)、 insert 、 query (是否存在前
缀)、 decrement 。空间约 $q(\ell - \log m + 2 \log \log \log u) + O(m)$ 。写入 D_i 的串来自
core set, 以匹配随机性假设。

§ 5 内部: $\text{main table} \rightarrow \text{subtable} \rightarrow \text{adaptive prefixes / navigator} \rightarrow \text{data blocks}$ (动态插入 + 后台重组静态)。位级冗余与式 (3)(4)(5) 精算以 A 为准; 未闭
合细节为 Q2/Q3。

操作流图: [figures/query-insert-flow.md](#)。

8. 正确性证明

对应 [notes/proof-table.md](#)。

8.1 无 false negative

命题: 无 failure 时, 已插入 key 的 Lookup 为 YES。

论证 (控制流, 已核实): 写入前缀或被更短前缀覆盖; 迁移边取边写、不丢串;
Lookup 同时查旧层与新层。

缺口：对所有 n 的形式存储归纳受阶段下标冲突阻塞 (issue-stage-index) —— 不写成已完全证明。

8.2 误报率 $\leq \epsilon$

命题：无 failure 时，非成员误报概率 $\leq \epsilon_0$ 。
骨架：式 (2) + 阶段/键 union bound (**A 精算**)；迁移不重复计费。依赖图：
figures/proof-dependency.md。

8.3 Prefix matching 与四结构覆盖

短串 τ 、长串 D ；查询固定四个活跃结构，避免扫 $\theta(\log n)$ 层历史 filter。

9. 时间和空间复杂度证明

9.1 时间 (B)

操作	论证	条件
Lookup	≤ 4 次底层 query + h 求值	$\neg \text{failed}$ ；底层 $O(1)$
Insert	$1 \times D.\text{insert} + 10 \times$ 维护轮；每轮常数底层调用	同上；字面 10 为原文/ $Q3$

§ 5 块重组同样去均摊到每次插入的常数步。

9.2 空间 (A 主核；B 结构约束)

Lemma 11 代入 $\ell_{\lceil \log n \rceil}$ 得主体 $n(\log(1/\epsilon) + \log \log n + O(\log \log \log u)) + u^{c_0}$ 。
B 确认：同时仅常数层 D/T 全量活跃，不保留 $\log n$ 个独立全量 filter。位级迁移峰值仍为 $Q3$ 。

9.3 Failure $\leq \delta$ (A)

每层 D_i 经式 (3)(4)(5) 等到 u^{-2C} ，对 $\leq \log u$ 层并合到 u^{-C} 。B 抽查骨架同意；自适应对手不作无条件扩张。

10. 技术优越性

【待 C；证据 S1-S4 见 evaluation-evidence.md】组合保证：unknown-size 空间主项 + 无 FN + $FP \leq \varepsilon + \text{whp}$ 最坏 $O(1)$ 。相对 PSW：领先常数与时间语义。非“全面优于 Bloom”。

11. 局限性与适用范围

【待 C】至少须保留：无用户删除；保证 conditioned on no failure； u^c 与 $n = \omega(\log u)$ ；实现远复杂于工程 Bloom；字面 10 与阶段下标为小组核查缺口 (L4)；删除模型有不同下界，不能反推本文错误。

12. 后续研究

【待 C】区分 insertion-only unknown-size、fully dynamic（含删除）、resizable-current- n ；E1/E2 不得作确定结论；2026 预印本标明状态。

13. 小组评价

【三人共同 · 待会后补】事实：论文在所述模型下给出同时达成空间主项与 whp 最坏常数时间的构造。观点：讲解主线宜强调四结构 + 去均摊迁移；Review 必须公开 Q1/Q3。

14. 结论

本文不是简单的“可扩容 Bloom”，而是 unknown-size 设定下，用哈希前缀、prefix matching、短串真值表、长串 succinct 结构与分阶段去均摊迁移，逼近信息论额外 $\log \log n$ 成本并追求最坏情况常数时间。读者应同时看到定理条件、与 PSW/工程方案的模型差异，以及本文整合稿中仍开放的下标与常数配平缺口。

15. 参考文献

【待 C 统一 BibTeX】正文已用关键文献：Liu-Yin-Yu ICALP 2020 / arXiv:2004.12465；Pagh-Segev-Wieder FOCS 2013（仓库 1304.1188v2.pdf）。引用审计见 references/citation-audit.md（C 主责；B 抽查技术章引用）。

附录 A. 开放问题（带入 Day 7）

ID	内容	正文处理
issue-stage-index	i★ vs 半开区间存储归纳	操作跟 i★；不声称归纳已证
issue-constant-10	字面常数 10	写原文 10 轮 + 未独立复算
Q2 data-block	§ 5 位级冗余	综述级；精算归 A
Q3 空间峰值	迁移瞬时位级	量级 O(n) 层；位级开放
A/C 章节	Day 5 定稿未入库	桥接段待替换

附录 B. 整合贡献（过程）

部分	主整合
§ 6– § 9（技术/实现/正确性/时间）及贯穿示例、图同步	B
§ 1– § 3、§ 5、§ 9 空间/failure 精算	A（待替换桥接）
§ 4、§ 10– § 12、§ 15	C（待替换桥接）
§ 13– § 14	共同